Os quatro sinais alinhados no mesmo eixo de passos (semente 0; 10.000 passos, lote 256)

vencedora: sgd 3e-2 cosseno
val_final 0.1611

baseline: adam 1e-4 constante
val_final 0.1667

muon 1e-3 warmup_cosseno
val_final 0.1747

instável: sgd 0,3 warmup_cosseno
val_final 0.1825

Huber

treino (lote)
treino (lote fixo)
validação

4×10^{-1}
3×10^{-1}
2×10^{-1}
10^{-1}
6×10^{-2}

‖g‖ (antes do corte; -- corte = 10)

10^{1}
10^{0}
10^{-1}

‖θ‖

3×10^{1}
2×10^{1}
10^{1}

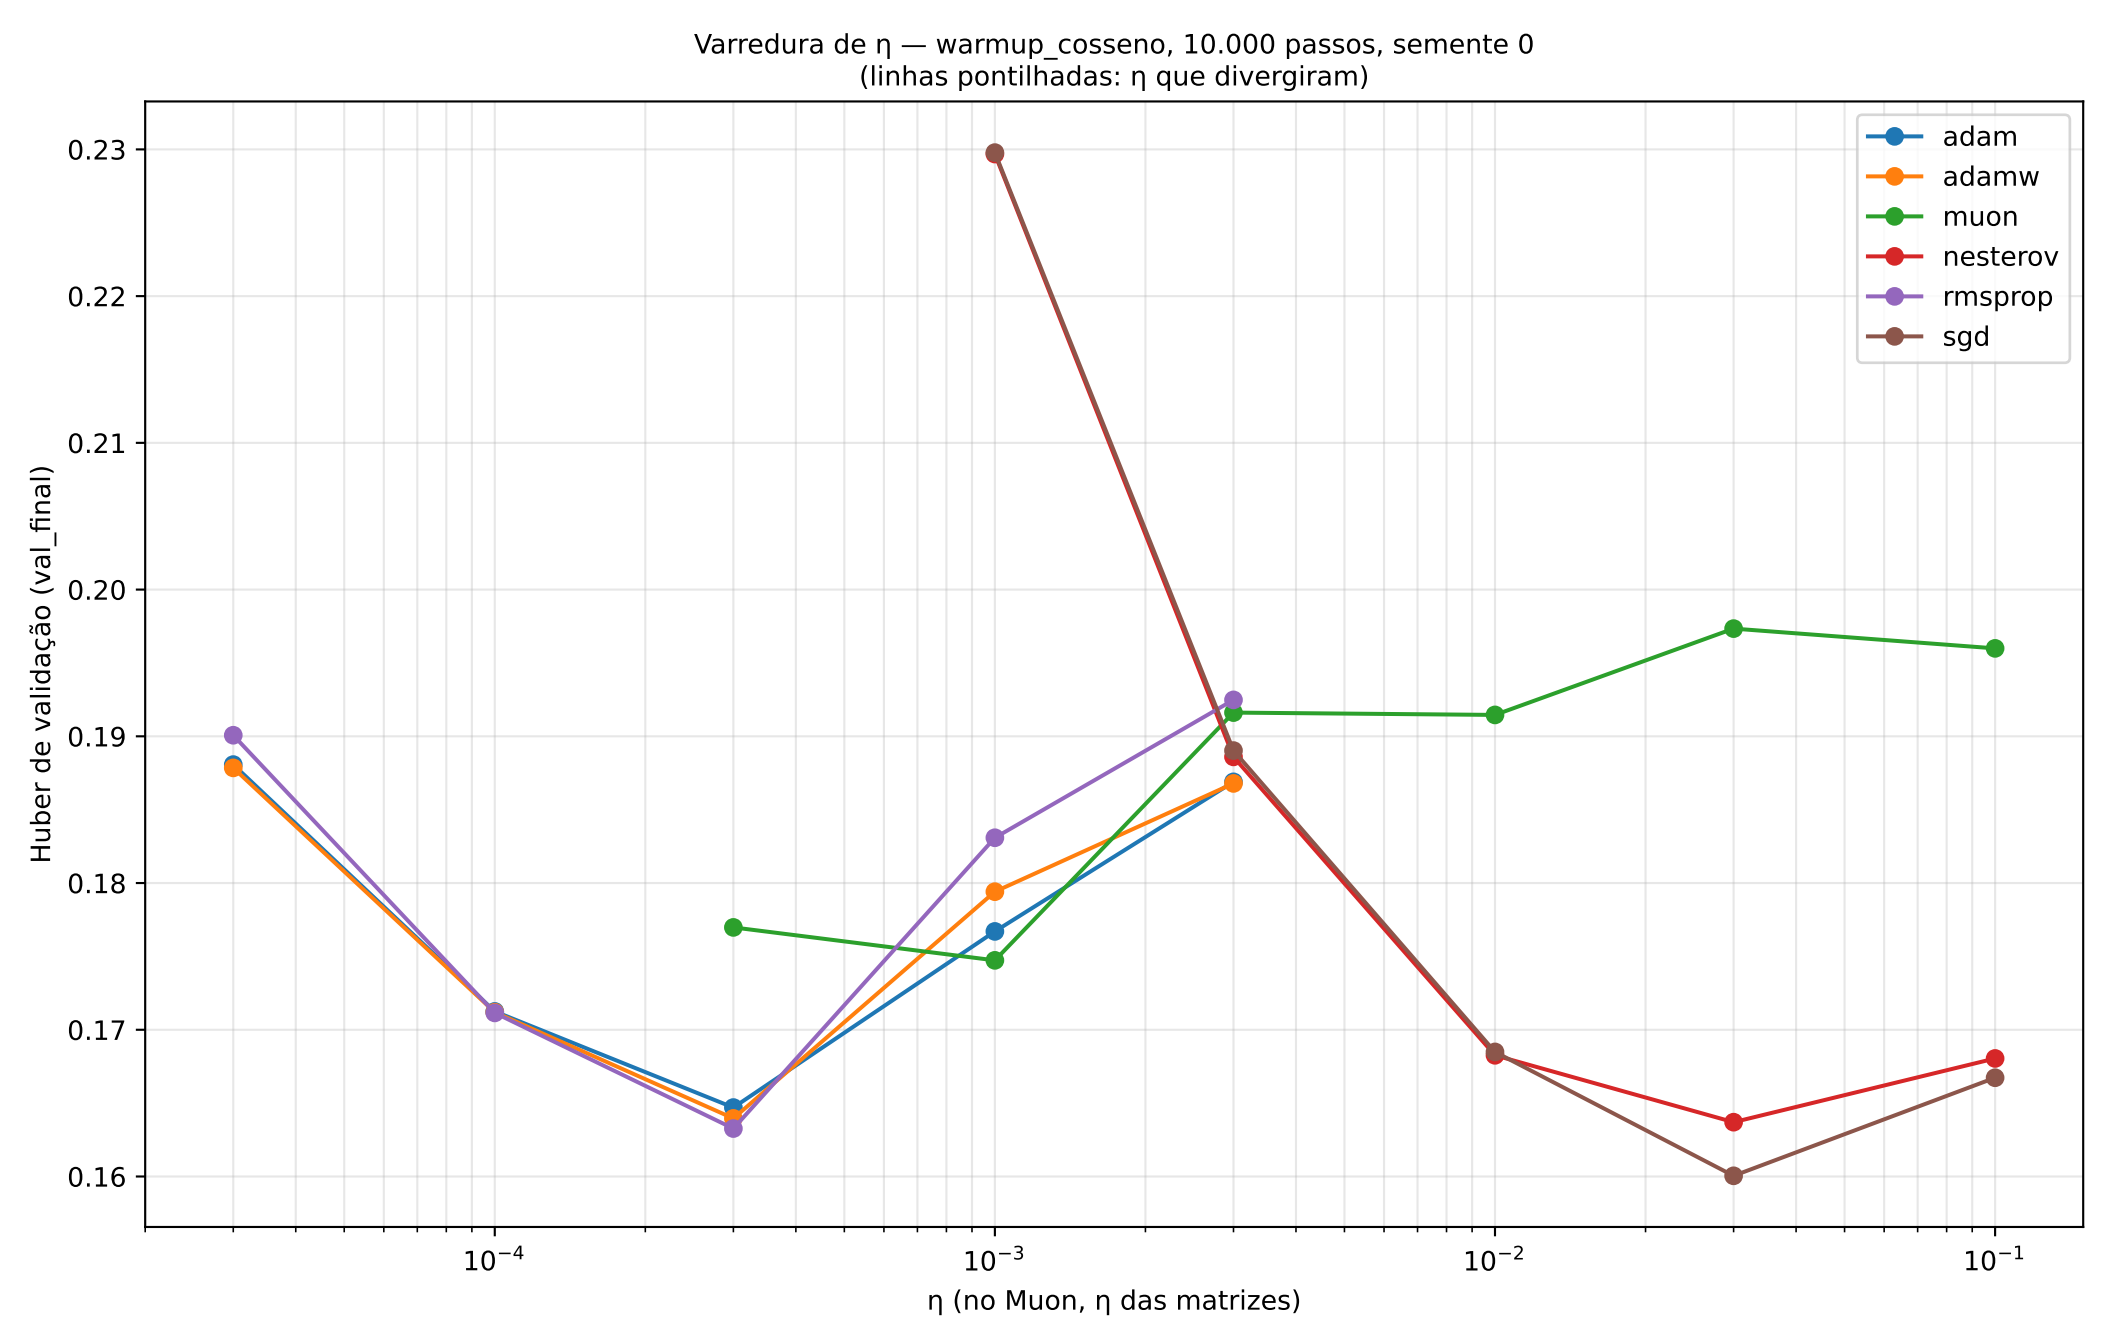
η

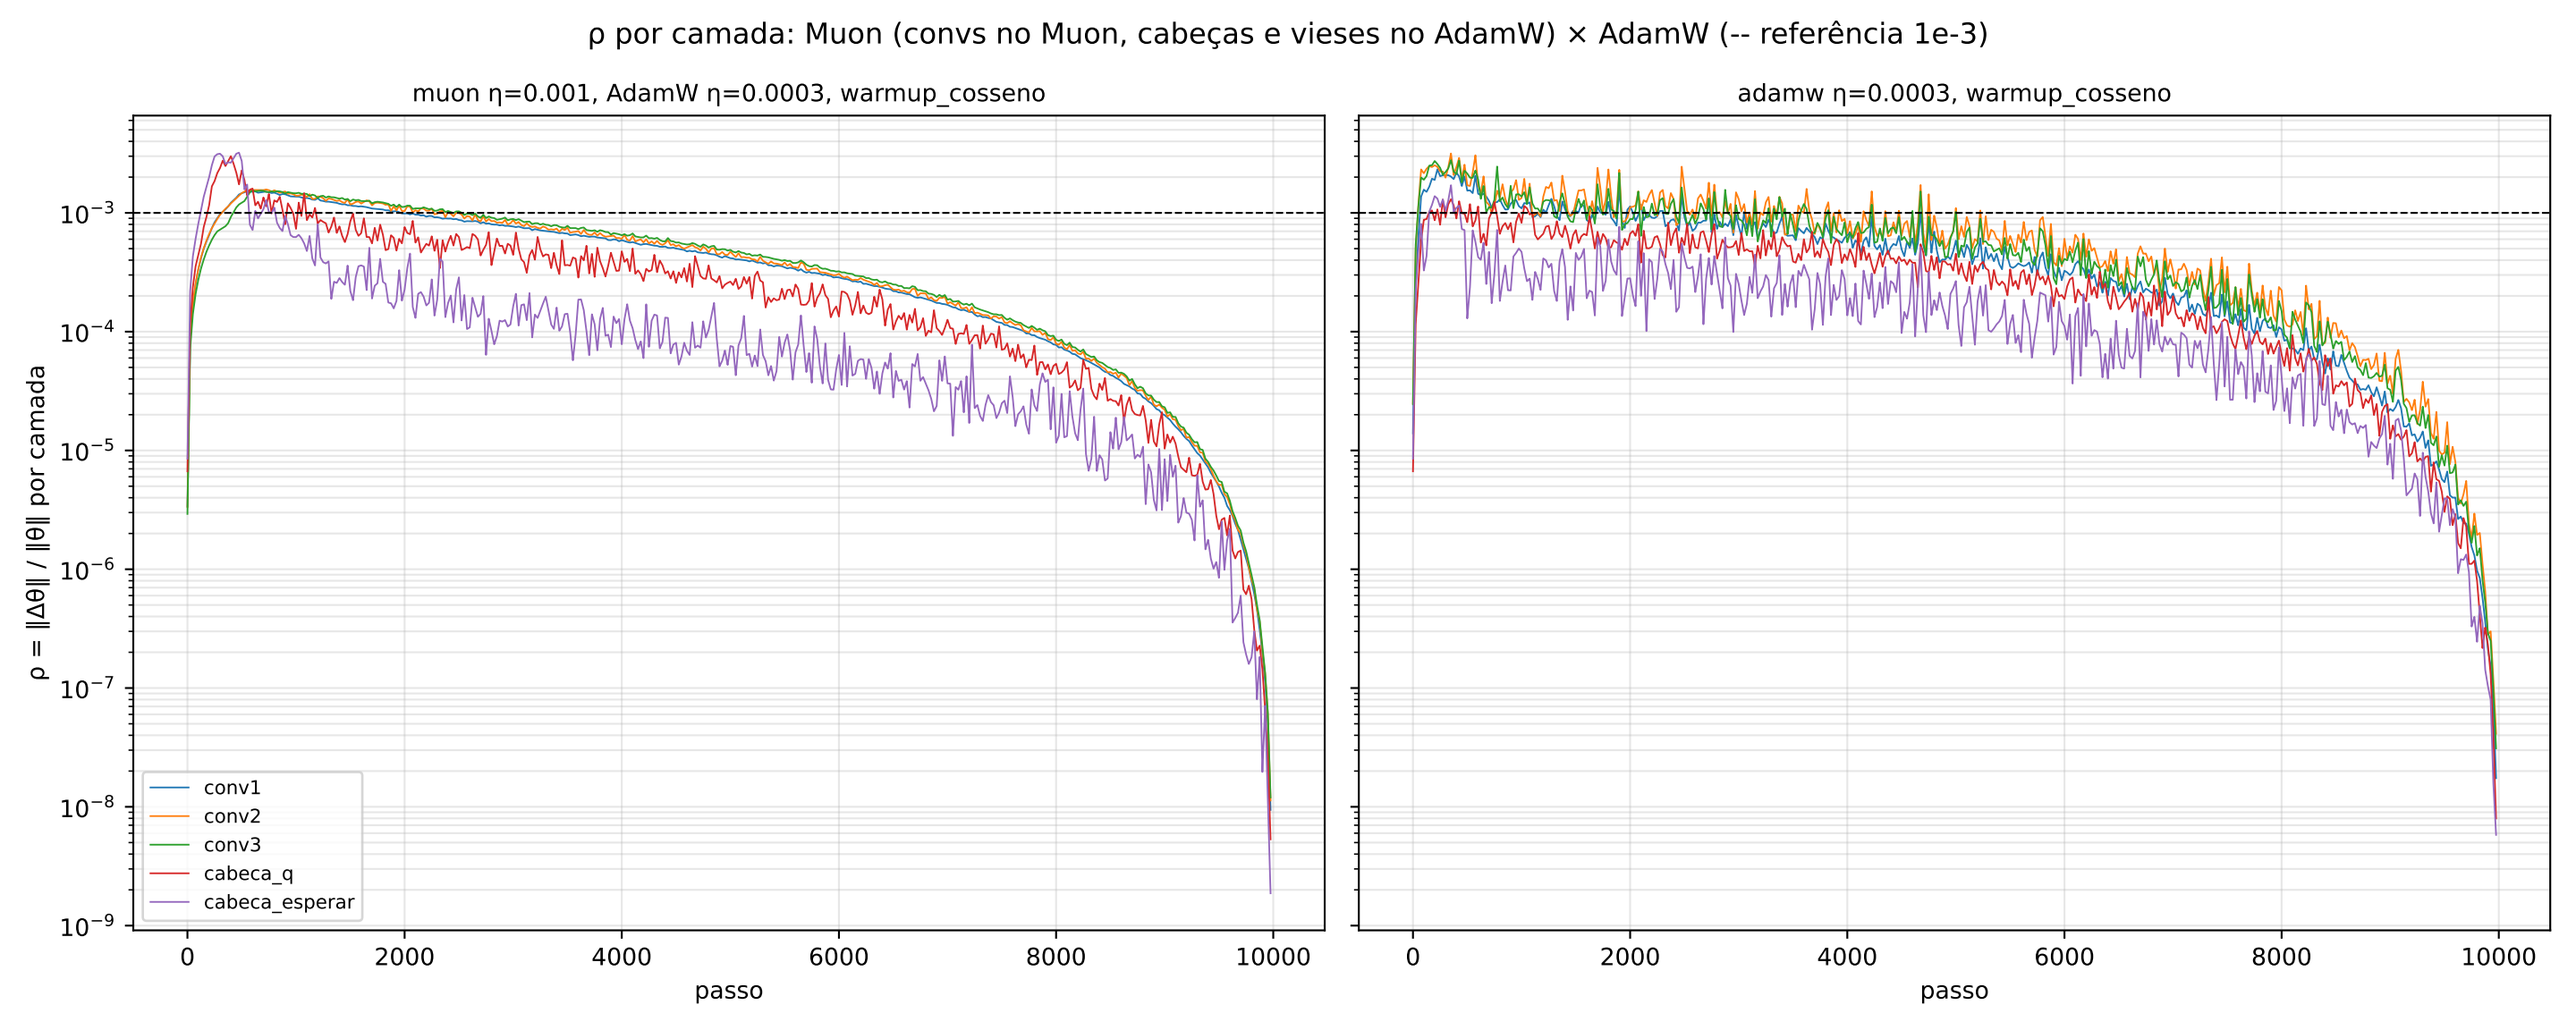
η
η Muon
η AdamW

10^{-1}
10^{-2}
10^{-3}
10^{-4}
10^{-5}
10^{-6}
10^{-7}
10^{-8}

0
2000
4000
6000
8000
10000

passo


Varredura de η — warmup_cosseno, 10.000 passos, semente 0
(linhas pontilhadas: η que divergiram)
Huber de validação (val_final)
η (no Muon, η das matrizes)
0.23
0.22
0.21
0.20
0.19
0.18
0.17
0.16
10^{-4}
10^{-3}
10^{-2}
10^{-1}
adam
adamw
muon
nesterov
rmsprop
sgd


ρ por camada: Muon (convs no Muon, cabeças e vieses no AdamW) × AdamW (-- referência 1e-3)
muon η=0.001, AdamW η=0.0003, warmup_cosseno
adamw η=0.0003, warmup_cosseno
ρ = ‖Δθ‖ / ‖θ‖ por camada
passo
passo
conv1
conv2
conv3
cabeca_q
cabeca_esperar

a) Treino × validação (média ± desvio, 5 sementes; Δ contra a baseline)

config	n	huber_treino	val_final	val_esperar	val_plantio	Δtreino	Δval	passo do val_min
baseline: adam 1e-4 constante	5	0.1463 ± 0.0036	0.1675 ± 0.0008	0.1623 ± 0.0010	0.1911 ± 0.0013	+0.0000	+0.0000	9750, 10000, 8250, 9250, 9250
sgd 3e-2 cosseno	5	0.1293 ± 0.0012	0.1623 ± 0.0022	0.1573 ± 0.0025	0.1843 ± 0.0021	-0.0171	-0.0053	5000, 6500, 8500, 5000, 7750
sgd 3e-2 warmup_cosseno	5	0.1312 ± 0.0027	0.1623 ± 0.0019	0.1574 ± 0.0019	0.1842 ± 0.0027	-0.0151	-0.0053	6750, 6500, 8500, 5000, 8750
rmsprop 3e-4 warmup_cosseno	5	0.1314 ± 0.0034	0.1623 ± 0.0014	0.1570 ± 0.0015	0.1860 ± 0.0010	-0.0149	-0.0052	5750, 6500, 6750, 8000, 7250
adam 3e-4 warmup_cosseno (extra)	5	0.1310 ± 0.0020	0.1661 ± 0.0016	0.1615 ± 0.0021	0.1867 ± 0.0012	-0.0154	-0.0014	8250, 6500, 8500, 5250, 7000
adamw 3e-4 warmup_cosseno (extra)	5	0.1310 ± 0.0020	0.1656 ± 0.0015	0.1609 ± 0.0019	0.1864 ± 0.0012	-0.0153	-0.0020	8250, 6500, 8500, 5250, 7000
muon 1e-3 warmup_cosseno	5	0.1112 ± 0.0012	0.1750 ± 0.0003	0.1714 ± 0.0004	0.1909 ± 0.0017	-0.0351	+0.0074	4000, 3500, 3250, 2750, 3250
muon 1e-1 warmup_cosseno (1 semente)	1	0.0628	0.1960	0.1932	0.2084	-0.0836	+0.0284	250

b) Velocidade (secundária): passos até val ≤ 0.1676 (subestima as agendas que decaem: medido dentro de uma execução de 10.000 passos)

config	passos até o alvo (por semente)	ms/passo
baseline: adam 1e-4 constante	8250, 10000, nunca, 8000, 8250	4.85
sgd 3e-2 cosseno	2750, 3500, 3500, 3250, 3250	3.79
sgd 3e-2 warmup_cosseno	3500, 3500, 3500, 3250, 4000	3.72
rmsprop 3e-4 warmup_cosseno	2750, 3000, 3250, 3000, 3500	4.00
adam 3e-4 warmup_cosseno (extra)	4000, 5000, 4750, 5250, 5250	4.00
adamw 3e-4 warmup_cosseno (extra)	4000, 3500, 4500, 5000, 4250	4.13
muon 1e-3 warmup_cosseno	nunca, nunca, nunca, nunca, nunca	7.44
muon 1e-1 warmup_cosseno (1 semente)	nunca	8.52

Teste (avaliado uma vez; Huber, média ± desvio, 5 sementes). Vencedora × baseline: empate (1,93 s_c); ambas vencem o Muon.

config	n	Huber total	esperar	plantio
vencedora: sgd 3e-2 cosseno	5	0.1344 ± 0.0034	0.1303 ± 0.0038	0.1535 ± 0.0019
baseline: adam 1e-4 constante	5	0.1394 ± 0.0013	0.1349 ± 0.0011	0.1604 ± 0.0027
muon 1e-3 warmup_cosseno	5	0.1438 ± 0.0017	0.1409 ± 0.0018	0.1569 ± 0.0018